

Notatki z Metod numerycznych

Jacek Olczyk

October 2018

Część I

Wykład

1 Rozwiązywanie układów równań liniowych

Znane metody

- $Ax = b, A \in \mathbb{R}^{n \times n}$
- Algorytm rozkładem LU (elim. Gaussa) z wybraniem el. gł $O(\frac{2}{3}N^3)$.
- 1. złota myśl numeryka: Co zrobić jeśli zadanie jest za trudne? Zmienić zadanie
- Zamiast rozwiązywać układ równań, przybliżamy go
- Czy da się szybciej niż Gauss, który jest $O(n^3)$? To jak nisko da się zejść to problem otwarty, ale istnieją algorytmy lepsze niż sześcian.

2 Przybliżone rozwiązywanie układów równań

- Niech $A = M - Z$, wtedy $Ax = Mx - Zx = b$, zatem $Mx = Zx + b$
- TODO Metoda iteracji prostej Banacha $Mx_{n+1} = Zx_n + b$
- Jeśli wybierzemy M tak, by układ z macierzą M można było tanio rozwiązać, wtedy iteracja też będzie tania
- Chcemy, żeby M było dobrym przybliżeniem A , ale nie aż tak łatwo że
- Metoda Jacobiego

$$a_{kk}x_k^{n+1} = b - \sum_{j \neq k} a_{kj}x_j^n$$

- inny pomysł, metoda Gaussa-Seidela: $a_{kk}x_k^{(n+1)} = b_k - \sum_{j < k} a_{kj}x_j^{(n+1)} - \sum_{j > k} a_{kj}x_j^{(n)}$

- Uwaga: fakt życiowy. Gdy n jest bardzo duże, wówczas w A jest zazwyczaj bardzo dużo zer, o ile układ pochodzi z REAL LIFETM.
- To oznacza, że ilość elementów różnych od 0 jest rzędu $O(n)$. Mówimy wtedy że macierz jest rzadka.
- Wniosek: Jeśli A ma $O(n)$ niezerowych elementów, to mnożenie Ax kosztuje też $O(n)$. Ponadto, rozwiązanie układu z macierzą dolnotrójkątną też jest $O(n)$

3 Normy macierzowe i wektorowe

Normy wektorowe

$$\|x\|_p := \left(\sum_{i=1}^N |x_i|^p \right)^{\frac{1}{p}}$$

$$\|x\|_\infty := \max_i |x_i|$$

Norma macierzowa

$$\|A\|_p := \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\|x\|_p} \|Ax\|_p$$

Własności normy macierzowej

1.

$$\|Ax\| \leq \|A\| \cdot \|x\| \quad \forall x \in \mathbb{R}^n$$

2.

$$\|Ax\|$$

- nie dało się przeczytać tablicy

3. tu też coś było :(

4 Warunek wystarczający zbieżności klasycznej metody iteracyjnej ($A = M - Z$)

$$Mx_{k+1} = b + Zx_k \quad (*)$$

Niech x^* będzie dokładnym rozwiązaniem $Ax^* = b$

$$\begin{aligned} x_{k+1} &= M^{-1}(b - Zx_k) \\ x_{k+1} - x^* &= M^{-1}(b - Zx_k) - x^* \\ &= M^{-1}(Ax^* - Zx_k) - x^* \end{aligned}$$

$$\begin{aligned}
&= M^{-1}(Ax^* - (M - A)x_k) - x^* \\
&= M^{-1}Ax^* + (I - M^{-1}A)x_k - x^* \\
&= -(I - M^{-1}A)x^* + (I - M^{-1}A)x_k - x^* \\
&= (I - M^{-1}A)(x^k - x^*)
\end{aligned}$$

Czyli B pomnożont błąd k -ty.

Czyli $x_{n+1} - x^* = B(x_k - x^*) = B^2(x_k - x^*) \dots = B^{k+1}(x_0 - x^*)$

Wniosek: Jeśli $\|B\| < 1$, to $(*)$ zbieżna do x^* dla dow. $x_0 \in \mathbb{R}^N$

Twierdzenie: Metoda $(*)$ jest zbieżna do x^* z dowolnego x_0 wtw gdy $\rho(B) < 1$ gdzie $\rho(B) = \max\{|\lambda| : \lambda \text{ jest wartością własną } B\}$ - promień spektralny macierzy B Dowód pominięty

Twierdzenie: Jeśli macierz A jest ściśle diagonalnie dominująca, tzn zachodzi $|a_n| > \sum_{j \neq i} |a_{ij}|$ dla $i = 1..N$ to metoda Jacobiego jest zbieżna (dla dowolnych $x_n \in \mathbb{R}^n$)

Dowód. Zbadajmy macierz iteracji.

$$\|B\|_\infty = \|I - M^{-1}A\|_\infty$$

M^{-1} dla macierzy diagonalnej to podnoszenie wszystkich elementów do -1 .

$M^{-1}A = I +$ macierz z zerami na diagonalu i ułamekami na reszcie, pierwszy wiersz to $0, a_{12}/a_{11}, a_{13}/a_{11} \dots$

Żeby uzyskać B odejmujemy I .

$$\|B\|_\infty = \max_i w_i$$

$w_i = \sum_j |b_{i,j}| = \sum_{j \neq i} |a_{ij}/a_{ii}| = \frac{1}{|a_{ii}|} \sum_{j \neq i} |a_{ij}| < 1$ zatem norma B jest mniejsza od 1 więc normy są zbieżne. \square

5 Metody iteracyjne oparte na normalizacji w przestrzeni Kryłowa

k -ta przestrzeń Kryłowa

$$K_k = r_0, Ar_0, \dots, A^{k-1}r_0$$

gdzie $r_k := b - Ax_k$ - reszta na k -tej iteracji

Metoda iteracyjna

- $x_k + 1 \in K_k$ przesunięta o x_0
- $x_k + 1$ normalizuje pewną miarę błędu na $x_0 + K_k$
- Na przykład:

$$\|x_k - X^*\|_C \leq \|y - x^*\|_C \forall y \in x_0 + K_k$$

lub

$$\|r_k\| \leq \|b - Ay\|_C \forall y \in x_0 + K_k$$

gdzie $C = C^T > 0$

5.1 Metoda gradientów sprzężonych (CG - Conjugate Gradient) dla macierzy $A = A^T > 0$

5.1.1 Fakty o macierzach symetrycznych i dodatnio określonych

Niech $A = A^T > 0$ (symetryczna i dodatnio określona, a co za tym idzie $x^T A x > 0$ dla $x \neq 0$). Wtedy:

1. Wartości własne są rzeczywiste a wektory własne są ortogonalne (czyli $A = Q\Lambda Q^T$, gdzie Q jest ortogonalna, a Λ jest diagonalna)
2. $\|x\|_A := \sqrt{x^T A x}$ określa normę wektorową (norma energetyczna indukowana przez A)

Iterację metody gradientów sprzężonych definiujemy następująco:

$$x_{k+1} \in x_0 + K_k$$

$$\|x_{k+1} - x^*\|_A \leq \|y - x^*\|_A \forall y \in x_0 + K_k$$

Ale przecież potrzebujemy mieć rozwiązanie żeby to zrobić!

Fakt. Można stąd wyprowadzić algorytm iteracyjny, który na podstawie kilku poprzednio wyznaczonych wektorów wyznaczy x_{k+1} kosztem jednego mnożenia przez macierz A i $O(N)$

Twierdzenie. Po k iteracjach metody CG błąd $\|x_k - x^*\|_A \leq 2\left(\frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}\right)^k \|x_0 - x^*\|_A$ gdzie $\alpha = \lambda_{\max}(A)/\lambda_{\min}(A)$.

Część II

Ćwiczenia

6 Układy nadokreślone - kontynuacja

6.1 Zadanie 1.

Macierz Hessenberga - to macierz trójkątna górna, z tym że niezerowe elementy mogą być jeden element pod diagonalą.

$$\begin{pmatrix} x & \dots & x & x \\ x & x & \dots & x \\ & x & & \end{pmatrix}$$

Jak najmniejszym kosztem znaleźć rozkład QR tej macierzy? Metodą Householdera? Nie ma jak wykorzystać zer na dole. Obrotami Givensa.

6.1.1 Obroty Givensa - przypomnienie

$$G_{ij} - \text{macierz Givensa } b = G_{ij}a, b_j = 0 \quad \cos \phi = \frac{a_i}{\sqrt{a_i^2 + a_j^2}} \quad \sin \phi = \frac{a_j}{\sqrt{a_i^2 + a_j^2}}$$

6.1.2 Zamiana macierzy Hessenberga w górnotrójkątną obrotami Givensa

$$(G_{ij}a)_j = -\frac{a_i a_j}{\sqrt{a_i^2 + a_j^2}} + \frac{a_i a_j}{\sqrt{a_i^2 + a_j^2}} = 0$$
$$G_{n-1} \dots G_{i+1} \dots G_{12} A = R$$

6.1.3 Koszt

Robimy $n-1$ iteracji. Dla G_{i+1} trzeba wykonać jeden pierwiastek, $w_i = cw_i + sw_{i+1}$ oraz $w_{i+1} = -sw_i + cw_{i+1}$, łącznie $4(n-1)$ mnożeń. Łącznie $4 \sum_{i=1}^{n-1} n-i = 4 \sum_{i=1}^{n-1} i = \frac{4n(n-1)}{2} \sim 2n^2$

6.2 Zadanie 2.

Dane są punkty $(-1, -1), (0, 2), (1, 0), (2, 1)$. Znajdź prostą $y = ax + b$ najlepiej przybliżającą te punkty (w sensie LZNK). (x_i, y_i) - punkty $y(x_i) - y_i$ - co chcemy zminimalizować. Policzmy normę: $\min_{a,b} \sum_{i=1}^4 (y(x_i) - y_i)^2$. Niewiadome to a oraz

b , więc niech $z = \begin{Bmatrix} a \\ b \end{Bmatrix}$ oraz $d = \{y_i\}_{i=1,2,3,4}$

$$A = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{pmatrix}$$

chcemy $\min \|Az - d\|_2$ Uwaga: w ten sposób odległość między punktami a prostą liczymy w pionie, a nie najbliższą (to dobrze, tak działa LZNK). Uwaga 2: LZNK nie działa dla równania $y = a + e^{bx}$, ale dla $y = a + be^x$ już tak!

7 Normy

dodatniość, liniowość z modulem, nierówność trójkąta wektorowe p-te:

$$\|x\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$$

$$\|x\|_\infty = \max_i |x_i|$$

Normy macierzowe $A \in \mathbb{R}^{n \times n}$ normy indukowane $\|A\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{\|x\|=1} \|Ax\|$
p-te normy macierzowe $\|A\|_p = \sup_{\|x\|_p=1} \|Ax\|_p, p = 1, 2, \dots, \infty$ wszystkie poza 1, 2, ∞ zwykle się pomija

7.1 Własności norm indukowanych macierzy

1. $\|Ax\| \leq \|A\| \|x\|$ - z definicji mamy $\|A\| \geq \frac{\|Ax\|}{\|x\|}$
2. $\|AB\| \leq \|A\| \|B\|, A, B \in \mathbb{R}^{n \times n}$ - bo

$$\|ABx\| \leq \|A\| \|Bx\| \leq \|A\| \|B\| \|x\|$$

oraz

$$\|AB\| = \sup_{x \neq 0} \frac{\|ABx\|}{\|x\|} \leq \|A\| \|B\|$$

Fakt. W przestrzeniach skończonego wymiaru wszystkie normy spełniają równanie: $\exists_{c_1, c_2 > 0} \forall_x c_1 \|x\|_1 \leq \|x\|_2 \leq c_2 \|x\|_1$, gdzie normy są dowolne (niekoniecznie 1-a i 2-a)

Zależności między normami $x \in \mathbb{R}^n$ $c_1 \|x\|_1 \leq \|x\|_2 \leq c_2 \|x\|_1$ Jak c_1 się ma do c_2 ? $\|x\|_1^2 = (\sum_i |x_i|)^2 \geq \|x\|_2^2 \|x\|_1 \leq \|x\|_2 \|x\|_1 \geq \|x\|_\infty n \|x\|_\infty \geq \|x\|_1 \|x\|_\infty \leq \|x\|_2 \sqrt{n} \|x\|_\infty \geq \|x\|_2 \|x\|_1 \leq n \|x\|_\infty \leq n \|x\|_2$ zatem $? = n$

Nierówności $\frac{1}{n} \|A\|_2 \leq \frac{1}{\sqrt{n}} \|A\|_\infty \leq \|A\|_2 \leq \sqrt{n} \|A\|_1 \leq n \|A\|_2$